

VLA 개요

Index

01

로봇제어의 개요

02

LLM
개념적 진화

03

VLA용 데이터셋

04

대표 VLA 모델 1

05

대표 VLA 모델 2

06

VLA의 숙제와 응용

01

로봇 제어의 개요

로봇 제어 방식의 진화 흐름

전통적 로봇 제어 (Rule-based / Teaching-based)

- 명확하게 정의된 경로·작업을 반복 수행

예: 팔레타이징, 용접로봇

비전 기반 제어 (Camera + Object Detection)

- 카메라로 객체 인식 → 좌표 계산 → 로봇 제어

예: 장애물 제거 후 목표 객체 집기

모방학습 기반 Trajectory 제어 (ACT, Diffusion Policy)

- 사람 시연 데이터를 기반으로 로봇 행동(trajecotory) 직접 학습


ACT: 행동을 chunk로 나누어 Transformer로 학습

Diffusion Policy: 연속적 trajectory를 생성하는 생성모델

VLA 기반 End-to-End 제어 (Plan → Task → Trajectory)


- 시각 + 언어 + 행동을 통합한 모델로 계획·인식·제어를 하나로

예: “주방 정리해줘” → 시각 인식 + 계획 수립 + 동작 생성



확산 모델

VLA



생성형 AI 등장 및 Embodied AI

생성형 AI 등장

- 생성형 AI → 로봇의 인지·추론·행동 방식 혁신
- 대규모 사전학습 → LLM·VLM의 일반화 능력 향상
- 기존 방식 한계 → 개별 저수준 작업을 위한 복잡한 정책 설계 필요
- VLA 장점 → 시각+언어 융합으로 향상된 추론 기반 로봇 제어

Embodied AI

- 물리적 실체(로봇 등)에 통합된 지능형 시스템(VLM)
- 인간 학습 방식과 유사: 경험·환경·상황에서 학습
- 시각적 단서 + 상호작용 기반 학습
- 현실 세계의 역동적 상황 처리 가능
- 인간 뇌 작동 방식 반영

이중 처리 이론(Dual Process Theory)

두 시스템은 고수준 계획과 저수준의 신속한 실행을 결합



대니얼 카너먼(Daniel Kahneman)의 이중 처리 이론(dual process theory) 모방

- 두 시스템 구조: 고수준 계획(System 2) + 저수준 신속 실행(System 1)
- 영감 원천: 대니얼 카너먼의 이중 처리 이론(Dual Process Theory) 모방
- 목적: 효율적 의사결정과 빠른 행동 수행 결합

2025년 상반기 기준, SOTA VLA

이중 레벨 전문가 시스템

- VLM과 디퓨전 디코더를 결합
- NVIDIA의 Groot N1, Figure AI의 Helix

범용 기반 정책


- Physical Intelligence의 $\pi_{0.5}$

시스템 2(“느린 사고”):


- 입력: 시각 + 텍스트
- 역할: 고수준 계획자(High-level planner)
- 기능: 복잡 상황·중간 작업 결정, 전체 행동 안내
- 방식: 목표 → 하위 작업 분할 → 다중모달 기반 추론 → 경로 생성

시스템 1(“빠른 사고”):

- 역할: 저수준 제어·정교한 이동 담당
- 모델: 트랜스포머 디코더 / 디퓨전 모델
- 장점: 풍부한 이미지 사전 지식 + 의미론적 장면 이해
- 동작: 시스템 2의 지시를 변환·실행 → 민첩·세밀한 동작 수행



확산형 모델과 LLM 기반 VLA



System 2 → System 1의 3단계 구조

1. Plan (고수준 계획) - System 2

1. 입력: 환경 관찰(카메라 센서) + 언어 명령
2. 역할:
 1. 목표 이해 및 시각·언어 통합 인식
 2. 환경 제약 고려한 전략적 계획 수립
3. 출력: **Task-level 목표**
(예: "책을 들어서 테이블 위에 올려놓기")

2. Task (중간 목표·세부 절차) - System 2 → System 1 연결

1. 입력: Plan 단계에서 생성된 고수준 목표
2. 역할:
 1. 목표를 달성하기 위한 단계별 작업 정의
 2. 예: "손 위치 조정 → 책 파지 → 이동 → 테이블 위 배치"
3. 출력: **Action Trajectory**의 시드 정보

3. Action Trajectory (저수준 연속 제어) - System 1

1. 입력: 중간 목표·상태(State) 정보
2. 역할:
 1. 고주파(Hz)로 실시간 모터·관절 제어
 2. 연속적이고 매끄러운 궤적 생성
3. 출력: **실제 로봇 제어 명령 시퀀스**

Robot Policy & Generalist Robot Policy(GRP)

[고려 사항]

- 범용성
- 경량화
- 정확성
- 실시간

Robot Policy

- 정의: 로봇이 현재 상태에서 목표 달성을 위해 어떤 행동을 할지 결정하는 규칙 집합
- 유형
 - 결정론적(Deterministic) - 각 상태에 특정 행동을 1:1 매핑
 - 확률적(Stochastic) - 각 상태별 가능한 행동의 확률 분포 제공
- 에피소드(Episode): 초기 상태 → 종료 상태까지의 상호작용 과정
 - 순서: 상태(s) → 행동(a) → 보상(r) → 다음 상태(s')
- 학습 방식
 - 강화학습: 보상 최대화로 최적 정책 학습
 - 모방학습/행동 복제: 관찰-행동 궤적을 학습해 올바른 행동 예측

GRP (Generalist Robot Policy)

- 하나의 범용 정책(policy) 모델로 다양한 로봇, 다양한 작업 환경, 다양한 작업 목표를 모두 수행할 수 있도록 설계된 로봇 제어 모델

02

개념적 진화

-
- LLM (Large-Language Model) / VLM (Vision-Language Model) / VLA (Vision-Language-Action)
 - 세 가지 개념 간 관계 정리
 - 주요기술 소개

LLM timeline






Fig. 1. A timeline of existing large language models (having a size larger than 10B) in recent years. We mark the open-source LLMs in yellow color.

LLM/VLM/VLA



LLM/VLM/VLA



LLM 학습 사전학습으로 기반 능력 확보 → SFT로 태스크 적합화 → RLHF로 품질 보정 → CoT로 복잡한 추론까지 강화

- LLM의 학습단계는 크게 Pre Training과 finetuning으로 나뉜다.
- finetuning에서도 크게 supervised fine tuning(SFT)와 reward modeling을 통한 RLHF 계열(PPO, DPO)로 나뉜다.
- 학습이 아닌 프롬프트에 내가 원하는 대로 답변을 잘할 수 있도록 Prompt engineering을 하게 된다.

• 사전학습(Pre-training)

- 초거대 텍스트(웹, 책, 코드 등)로 다음 토큰 예측 학습
- 언어 패턴·지식·추론의 기초 능력 확보

• 지도형 미세조정 (Supervised Fine-Tuning, SFT)


- 질문 → 정답 데이터로 학습
- 모델을 대화형·과제 특화로 맞춤
- CoT 적용 시: 질문 → 사고 과정 → 정답 구조로 학습

• 강화학습 기반 미세조정 (RLHF 계열: PPO, DPO 등)

- 사람(또는 AI) 피드백으로 “좋은 답 vs 나쁜 답” 비교
- 모델이 정확하고 유용한 답변을 선택하도록 강화
- 부작용 억제(할루시네이션, 공격적 답변 등)

• Chain of Thought (CoT)

- 정답만 출력 → 사고 과정을 드러내며 출력으로 전환
- 프롬프트 엔지니어링(“step by step”)만으로도 유도 가능
- SFT/RLHF와 결합 시 안정적 reasoning 모델 완성



- CoT는 단순히 “프롬프트 엔지니어링 트릭”에서 출발했지만,
- 현재는 SFT + RLHF로 안정화된 핵심 학습 파이프라인이 됨.
- Fine tuning : GRPO도 사용가능

지도 학습 미세 조정 (SFT)

고품질 데이터의 중요성

LIMA, PHI와 같은
고품질 데이터셋이 필수적입니다.



적은 데이터로 큰 효과

30-50개의 고품질 예시만으로도
스타일 전환이 가능합니다.



독스트링(Docstring)

주석을 명확하게 정리한 데이터가
교육적 가치가 높음



Less Is More for Alignment(Meta, 2023)
<https://arxiv.org/abs/2305.11206>)

인간 피드백 기반 강화 학습 (RLHF)

1

1. SFT 모델 생성

기본적인 답변 능력을 확보합니다.

2

2. 보상 모델 학습

인간 평가자의 선호도를 학습합니다.

(예> A와 B중 어떤 코드가 가독성이 더 좋은가 등)

3

3. PPO를 통한 강화 학습

보상을 최대화하는 방향으로 정책을 최적화합니다.

어느것이 더 판별력 있는 질문인가요?




질문 1. 양양의 점수를 주세요...


50점이에요... 왜요?

질문 2. 양양과 강릉 중 어디가 나아요?

양양이요



PPO와 GRPO





Multimodal LLM

텍스트뿐만 아니라 이미지, 비디오, 오디오, 3D 등 다양한 형식의 데이터를 이해하고 생성할 수 있는 LLM

- 텍스트와 이미지 처리 활발
- 비디오, 오디오, 3D는 초기 단계

- Image encoder : ViT/ResNet/DINO




CLIP(Contrastive Language-Image Pretraining)

- CLIP은 OpenAI에서 2021년에 공개한 모델
- 일반 모델: 이미지 → 특징 추출 + 선형 분류기 → 레이블 예측
- CLIP: 이미지 인코더 + 텍스트 인코더 → (이미지, 텍스트) 매칭 학습
- 테스트 시: 텍스트 인코더로 클래스 설명을 임베딩 → 제로샷 분류 가능
즉, CLIP은 텍스트를 활용해 새로운 클래스에 대해 학습 없이도 분류가 가능하다.


SigLIP(Google, 2023)은 CLIP의 대안
Sigmoid loss를 사용해 학습 안정성과 성능 개선

더 간단한 학습 구조로 CLIP보다 효율적
대규모 데이터에서 강력한 성능을 보임

(1) Contrastive pre-training



(2) Create dataset classifier from label text



(3) Use for zero-shot prediction

CLIP: SoftMax

$$-\frac{1}{2|B|} \sum_{i=1}^{|B|} \left(\log \frac{e^{t\mathbf{x}_i \cdot \mathbf{y}_i}}{\sum_{j=1}^{|B|} e^{t\mathbf{x}_i \cdot \mathbf{y}_j}} + \log \frac{e^{t\mathbf{x}_i \cdot \mathbf{y}_i}}{\sum_{j=1}^{|B|} e^{t\mathbf{x}_j \cdot \mathbf{y}_i}} \right)$$

SigLIP: Sigmoid



$$-\frac{1}{|B|} \sum_{i=1}^{|B|} \sum_{j=1}^{|B|} \log \frac{1}{1 + e^{z_{ij}(-t\mathbf{x}_i \cdot \mathbf{y}_j + b)}} \quad \mathcal{L}_{ij}$$

VLA - Flow matching

- 개념
 - 분포 간 변환을 연속적 ODE(벡터장)로 학습
 - 초기 분포(노이즈) → 목표 분포(데이터)까지 연속적 경로 이동
- 동작 원리
 1. 벡터장 $v(x, t)$: 시간·위치별 방향과 속도 정의
 2. 미분값으로 최적 방향·크기 추정
 3. 한 스텝 적분 → 갱신
 4. 반복: 노이즈 → 데이터 도달
- 특징 (Diffusion·Flow 대비)
 - Diffusion : 점진적 변환 + Flow: invertible mapping
 - 빠른 샘플링 + 표현력 우수
 - Deterministic

Flow Matching

- '시간에 따른 벡터장을 따라 노이즈에서 데이터로 이동하는 생성 모델'






03

VLA용 데이터셋

- LLM/VLM/VLA 모델
- Open X-Embodiment 데이터셋
- BridgeData V2
- VLA model history

LLM/VLM/VLA

모델 종류	입력	출력	예시
LLM	텍스트	텍스트	GPT, LLaMA Gemini PALM, GLaM, T5, Gemma
VLM	이미지 (+ 텍스트)	텍스트	BLIP, Flamingo PALI-X, PALM-E, Prismatic 7B, PaliGemma
VLA	이미지 + 텍스트 + 로봇 상태	로봇 행동	OpenVLA, π_0 , RT-2



Open X-Embodiment 데이터셋

- UC Berkeley, Google DeepMind, CMU, Columbia 등 여러 연구 기관이 협력하여 구축한 대규모 범용 로봇 데이터셋
- Vision-Language-Action (VLA) 기반 로봇 모델의 범용성과 일반화 성능을 키우기 위해 만들어졌으며, 최근의 대표 모델인 OpenVLA와 Octo, 그리고 (Pi Zero) 등의 학습 기반이 되는 핵심 자원



항목	내용
이름	Open X-Embodiment
구성 로봇 수	22개 기관에서 150종 이상의 로봇
총 시퀀스 수	약 500M frames 이상
총 작업 수	527개 이상
라벨 형태	이미지 + 자연어 명령 + action (or trajectory)
목적	범용 로봇 제어 모델 학습 (VLA 기반)
라이선스	공개, 오픈소스 (논문 기준: arXiv:2309.06621)

Open X-Embodiment 데이터셋

주요 특징

1. 다양한 로봇 환경 통합

- 실제 로봇(예: Franka, Sawyer, UR5, WidowX)부터 시뮬레이터 로봇까지 포함
- 다양한 하드웨어 조건(팔 길이, 관절 수, gripper 형태 등)을 포괄

2. 범용성 (Generalization) 목표

- 기존 데이터셋은 하나의 로봇 + 하나의 도메인 중심이었음
→ Open-X는 다양한 환경과 로봇의 시퀀스를 결합하여 범용성 확보 가능

3. 명령어 중심 데이터 구성

- 각 로봇 행동 시퀀스는 자연어 명령어로 조건화됨
 - 예: "Pick up the red block and place it in the bin"

4. 멀티모달 구성

- (이미지, 명령어, 행동) 세트로 구성됨
 - 이미지: RGB 또는 RGB-D
 - 명령어: 자연어 문장
 - 행동: Cartesian pose, joint angle, gripper (↓) 등

데이터 구성 예시

```
json                                                                    🔍 복사    ✎ 편집

{
  "image": "rgb_frame_00123.jpg",
  "language_instruction": "Put the orange in the bowl",
  "robot_action": [x, y, z, roll, pitch, yaw, gripper_open]
}
```

또는 π_0 스타일 trajectory 형식의 경우:

```
json                                                                    🔍 복사    ✎ 편집



{
  "image": "frame_00123.jpg",
  "language": "Move the blue cup to the corner",
  "trajectory": [[pose1], [pose2], ..., [poseN]]
}
```

학습에 활용된 모델

- **OpenVLA**: OpenX-Embodiment 데이터셋 기반으로 사전학습된 Prismatic-7B + Policy Head
- **Octo**: 마찬가지로 OpenX 데이터 기반으로 fine-tuning
- π_0 는 다른 데이터셋(LeRobot)을 사용했지만 OpenX와의 유사한 멀티로봇 구조를 지향함

BridgeData V2 <https://rail-berkeley.github.io/bridgedata/>

- UC Berkeley RAIL 연구팀이 제작한 로봇 조작 데이터셋, 범용 VLA 학습 및 평가 지원
- 주로 WidowX250 (6-DOF) 로봇암을 사용, 다양한 환경과 태스크 시연 수집
- 총 60,096 trajectories 포함, 이 중 5만여 개는 사람이 직접 teleoperation으로 수행
- 24개 환경(toy kitchen, table-top 등)과 13개 스킬(pick, place, drawer open, folding 등) 커버
- 시각 데이터는 어깨 위·랜덤 시점·손목 카메라에서 촬영, 해상도 640×480 픽셀
- 각 trajectory는 자연어 지시 또는 목표 이미지와 함께 제공되어 조건부 학습에 활용됨
- 데이터는 NumPy / TFRecord / RLDS 포맷으로 제공, GitHub 코드로 BC·Diffusion Policy·IQL 학습 가능
- Open X-Embodiment보다 소규모, 재현성과 일관성이 높아 일반화 성능 평가용 벤치마크로 쓰임



VLA(Vision Language Action) Model History

- RT-1 (Google DeepMind) - 2022년 12월
- RT-2 (Google DeepMind) - 2023년 7월
- QUAR-VLA (MiLAB) - 2023년 12월
- Octo (UC Berkeley) - 2024년 5월
- OpenVLA(Stanford) - 2024년 6월
- $\pi 0$ (Physical Intelligence) - 2024년 11월
- OpenVLA-OFT(Stanford) - 2025년 1월
- Helix (Figure AI) - 2025년 2월 20일
- GR00T N1 (NVIDIA) - 2025년 3월 18일
- Gemini Robotics (Google DeepMind) - 2025년 3월
- $\pi 0.5$ (Physical Intelligence) - 2025년 4월
- SmolVLA(LeRobot) - 2025년 6월

04

대표 VLA Model - I

RT-1 (Google DeepMind) - 2022년 12월

RT-2 (Google DeepMind) - 2023년 7월

QUAR-VLA (MiLAB) - 2023년 12월

Octo (UC Berkeley) - 2024년 5월

OpenVLA(Stanford) - 2024년 6월

$\pi 0$ (Physical Intelligence) - 2024년 11월

OpenVLA-OFT(Stanford) - 2025년 1월

Helix (Figure AI) - 2025년 2월 20일

GR00TN1 (NVIDIA) - 2025년 3월 18일

Gemini Robotics (Google DeepMind) - 2025년 3월



$\pi 0.5$ (Physical Intelligence) - 2025년 4월

SmolVLA(LeRobot) - 2025년 6월


RT-1/RT-2

LLM 사전학습/SFT-VLM 사전 학습/SFT- VLA 사전학습/SFT

항목	PaLI-X	PaLM-E
LLM Core	✅ PaLM (LLM)	✅ PaLM (LLM)
Vision Encoder	SigLIP	ViT (Vision Transformer)
입력 modality	텍스트 + 이미지	텍스트 + 이미지 + 로봇 상태(sensor)
사용 목적	VQA, captioning 등 VLM	로봇 제어까지 포함한 Embodied AI
VLM 전용인가?	VLM 특화	VLM + 로봇용 LLM 확장형



Robotics Transformer 1 (RT-1 2022)





성능과 일반화 능력이 향상

- 이유: RT-1은 여러 작업, 물체, 환경을 포함하는 다양한 로봇 궤적 데이터를 대량 흡수

기존 베이스라인


- 큰 데이터셋을 완전히 활용하는 능력 제한적



Pathways Language Model-Embodied (PaLM-E)

❖ PaLM-E: An Embodied Multimodal Language Model (ICML, 2023, 1630회 인용)

- 사전학습된 거대언어모델 PaLM에 이미지-텍스트, 제어 데이터를 기반으로 multi-modal 학습
- 현실 세계를 효과적으로 표현할 수 있도록 vision-language-model을 활용하여 로봇 제어 수행
- 다만 PaLM-E는 지시사항을 다수의 세부 절차로 나누어 주는 역할을 하며 실질적인 움직임은 RT-1이 수행



Pathways Language Model–Embodied (PaLM-E)

❖ Co-training Strategy

- 사전학습된 PaLM (8B, 62B, 540B)에 이미지, 텍스트, 로봇 조종이 유기적으로 연관된 데이터를 학습하여 multi-modal large language model 생성

Language Only Task

Visual Q&A



Given . Q: What's in the image? Answer in emojis.

A: 🍏 🍊 🍇 🍌 🍓 🍓

Captioning



Describe the following :

A dog jumping over a hurdle at a dog show

Mobile Manipulation



Human: Bring me the rice chips from the drawer. Robot: 1. Go to the drawers, 2. Open top drawer. I see .

3. Pick the green rice chip bag from the drawer and place it on the counter

Given <emb> ... Q: How to grasp blue block? A: First, grasp yellow block



Large Language Model (PaLM)

After Training → PaLM-E

A: First, grasp yellow block

구글의 RT-2

- 모델 유형: 비공개 Vision-Language-Action 모델
- 백본: PaLI-X(55B) or PaLM-E(12B)
- 입력: 로봇 카메라 이미지 + 자연어 질의
- 출력: 이산형 액션 토큰 → 디토큰화 → 로봇 제어 코드
- 학습 데이터: 웹 규모 시각-언어 데이터 + 로봇 행동 데이터 비중 강화
- 특징: COT(Chain-of-Thought) 추론, 과제 일반화 능력, 작업별 정책 불필요
- 성과: 훈련받지 않은 작업(사람 인식, 기호 이해 등) 수행 가능
- 의의: 웹 스케일 사전학습 + 행동 토큰화를 통한 최초의 고도 일반화 VLA 사례

Prompt:
Given Instruction:
Bring me a drink.
Prediction:
Plan: pick 7up can.
Action: 1 143 129 123 145
114 115 127



Prompt:
Given Instruction:
Move all the objects
together.
Prediction:
Plan: move green can near
green rice chip bag.
Action: 1 128 126 127 135
123 119 127





Prompt:
Given Instruction:
Pick the object that is
different from all other
objects
Prediction:
Plan: pick rxbar
chocolate. Action: 1 128
129 125 131 125 128 127



Prompt:
Given Instruction:
Move the green objects
together.
Prediction:
Plan: move green can near
green rice chip bag.
Action: 1 130 129 121 131
127 128 127




Prompt:
Given I need to
hammer a nail, what
object from the scene
might be useful?
Prediction:
Rocks. Action: 1 129 138
122 132 135 106 127



QUAR-VLA: MiLAB의 사족보행 로봇

- 대상 로봇:
사족보행 로봇(Quadruped Robots)
- 목표:
복잡한 지형에서의 내비게이션 및 다양한 작업 수행
- 데이터셋:
실세계 + 합성 데이터 혼합,
내비게이션·복잡 지형 보행 포함
- 입력:
관찰 이미지 + 사용자의 언어 지시
- 모델 구조:
 - 언어 지시를 토크나이즈 후 이미지와 결합
 - 사전학습된 VLM을 통해 2Hz로 이산(Discrete) 액션 토큰 생성
- 액션 표현:
연속형 행동 공간을 255개의 이산 구간으로 양자화하여 학습 및 실행



UC 버클리의 Octo

1. 모델 개요

1. 93M 파라미터, 트랜스포머 기반 오픈소스 일반 로봇 정책 모델
2. OpenX-Embodiment 데이터셋 80만 로봇 시연으로 학습
3. 성능: RT-2(55B)급 대형 모델과 유사한 결과

2. 입력 처리


1. 언어 지시 → Task 토큰으로 언어 인코더 처리
2. 관측 이미지 → CNN 인코더로 Observation 토큰 생성
3. 두 토큰을 트랜스포머에 함께 입력

3. 액션 생성

1. 디퓨전(decoder) 기반 액션 토큰 생성 (이산 토큰보다 성능 우수)
2. 손목·3인칭 시점 등 다양한 관측 입력 지원
3. 소량의 시연 데이터로 손쉬운 파인튜닝 가능

4. 모델 변형

1. Octo-Tiny / Octo-Small / Octo-Base(93M) 제공
2. 공개된 기본 예제 코드에서 오류 수정판 존재



스탠퍼드의 OpenVLA

1. 모델 규모

1. 7B 파라미터 LLM 기반, 970K 에피소드 (Open X-Embodiment 데이터셋) 학습

2. 구성 요소

1. 이중 비전 인코더: DINOv2(공간 관계 강점) + SigLIP(언어 정렬 강점)
2. 프로젝터(MLP): 비전 임베딩을 LLM 공간으로 매핑
3. LLM(Llama2 7B): 시각·언어 토큰을 받아 연속 액션 생성

3. 액션 특징

1. 위치, 회전, 그리퍼 상태 등 연속 제어 신호 출력
2. 255개의 액션 토큰으로 전체 액션 공간 표현 가능

4. 성능 특성


1. RT-2-X(55B)보다 우수한 성능(파라미터 7배 작음)
2. Out-of-Distribution(OOD) 환경에서는 웹 데이터 학습한 RT-2 대비 약점

5. 튜닝 지원

1. LoRA 등 PEFT(Parameter-Efficient Fine-Tuning) 적용 가능
2. OOD 환경 적응 위해 소량 데이터 파인튜닝 효과적

OpenVLA = Prismatic VLM + Action Decoder

Open X-Embodiment 데이터셋



RT-2-X:
Move Coke Can near Taylor Swift
(OOD: unseen concept from Internet)




OpenVLA:
Move Coke Can near Taylor Swift
(OOD: unseen concept from Internet)



OpenVLA 프로젝트 목표

What is OpenVLA?


- 7B VLA built on pretrained “Prismatic VLM” backbone
- LLM: Llama 2
- Vision: DINOv2 + SigLIP



OpenVLA 프로젝트 목표

What is OpenVLA?

- 7B VLA built on pretrained “Prismatic VLM” backbone
- LLM: Llama 2
- Vision: DINOv2 + SigLIP



What is OpenVLA trained on?

- 970k episodes from Open X-Embodiment dataset
 - 27 real robot datasets
- Trained on 15 more datasets than RT-2-X


Fully
Open-Source



OpenVLA 프로젝트 목표

What is OpenVLA?

- 7B VLA built on pretrained “Prismatic VLM” backbone
- LLM: Llama 2
- Vision: DINOv2 + SigLIP




What is OpenVLA trained on?

- 970k episodes from Open X-Embodiment dataset
 - 27 real robot datasets
- Trained on 15 more datasets than RT-2-X

OpenVLA Inputs / Outputs?


- Inputs: Prompt w/ single image & language instruction
 - $\langle \text{Image} \rangle$ In: What action should the robot take to put eggplant into pot?
- Out:
- Outputs: Tokenized robot action

OpenVLA 프로젝트 목표



Which robots can OpenVLA control? •WidowX, Google robot, Franka, & several more!

OpenVLA 프로젝트 목표



All open-sourced! :)

실험 (Experiments)

- Main experiments:
 - **(1) How does OpenVLA compare to prior generalist robot policies when deployed out of the box?**
 - **(2) Can OpenVLA be effectively fine-tuned on a new robot setup/task?**
- Additional experiments:
 - (3) Can we use parameter-efficient fine-tuning methods (e.g., LoRA) to fine-tune OpenVLA efficiently with a smaller compute budget?
 - (4) Can we use inference-time quantization to load & run OpenVLA with limited GPU memory?

실험 #1 - Out-of-the-Box 평가

Sample visual generalization tasks

Put Cup from Counter into Sink



(unseen cup color)

Put Eggplant into Pot



(unseen pot)

Put Yellow Corn on Pink Plate



(unseen clutter / distractor objects)

Sample motion generalization tasks

Lift Eggplant



(unseen object position)

Put Carrot on Plate



(unseen plate height)

Sample physical generalization tasks

Flip Pot Upright



(unseen pot size/shape)

Lift AAA Battery



(unseen target object size)

Sample semantic generalization tasks

Move Skull into Drying Rack



(unseen target object)

Stack Blue Cup on Pink Cup



(unseen language instruction)

Sample language grounding tasks

Put **Eggplant** into Pot




Put **Red Bottle** into Pot



실험 #1 - Out-of-the-Box 평가

BridgeData V2 Results



OpenVLA performs best overall, outperforming next best model (RT-2-X) by +20%

OpenVLA is strongest in most task categories


Exception: For semantic gen, RT-2-X performs best

Potentially due to:

- (1) Larger-scale Internet pretraining
- (2) Co-fine-tuning on both robot data + VLM pretraining data

실험 #1 - Out-of-the-Box 평가

Google RT-X Robot Results




OpenVLA and RT-2-X perform comparably (overlapping error bars)

RT-1-X and Octo performance is also comparable

Both underperform compared to the VLA models

실험 #2 — 파인튜닝 평가 (Fine-Tuning Evals)


Fine-Tuning Results



OpenVLA shows strongest performance on average: outperforms next best baseline by +20.4% (absolute)

Also: Only method to get at least 50% success in all tasks

실험 #2 — 파인튜닝 평가 (Fine-Tuning Evals)



OpenVLA trained from scratch (no OpenX pretraining) struggles overall — showing that robot pretraining is crucial for good fine-tuning performance

추가 실험 (Additional Experiments)

Parameter-Efficient Fine-Tuning Results

Strategy	Success Rate	Train Params ($\times 10^6$)	VRAM (batch 16)
Full FT	69.7 ± 7.2 %	7,188.1	163.3 GB*
Last layer only	30.3 ± 6.1 %	465.1	51.4 GB
Frozen vision	47.0 ± 6.9 %	6,760.4	156.2 GB*
Sandwich	62.1 ± 7.9 %	914.2	64.0 GB
LoRA, rank=32	68.2 ± 7.5 %	97.6	59.7 GB
rank=64	68.2 ± 7.8 %	195.2	60.5 GB

LoRA is most effective: With rank=32, trains only 1.4% of model params but matches full fine-tuning performance!

추가 실험 (Additional Experiments)

- Q: Do we need a GPU with large memory to run OpenVLA models?
- **4-bit quantization (at inference time)**
 - Normally, we cast OpenVLA to bfloat16 at test time → Requires ~16 GB VRAM
 - What if we use int4 quantization?
 - Results (on subset of BridgeData V2 tasks)

Precision	Bridge Success	VRAM
bfloat16	$71.3 \pm 4.8\%$	16.8 GB
int8	$58.1 \pm 5.1\%$	10.2 GB
int4	$71.9 \pm 4.7\%$	7.0 GB

- **TLDR:**
 - Only need 7 GB VRAM to run OpenVLA with 4-bit quantization
 - Did not observe degradation in performance in our evals!
 - (8-bit quantization performs poorly... possibly due to low inference speed)

05

대표 VLA Model - II

RT-1 (Google DeepMind) - 2022년 12월

RT-2 (Google DeepMind) - 2023년 7월

QUAR-VLA (MiLAB) - 2023년 12월

Octo (UC Berkeley) - 2024년 5월

OpenVLA(Stanford) - 2024년 6월

$\pi 0$ (Physical Intelligence) - 2024년 11월

OpenVLA-OFT(Stanford) - 2025년 1월

Helix (Figure AI) - 2025년 2월 20일

GR00TN1 (NVIDIA) - 2025년 3월 18일

Gemini Robotics (Google DeepMind) - 2025년 3월

$\pi 0.5$ (Physical Intelligence) - 2025년 4월

SmolVLA(LeRobot) - 2025년 6월

π Physical Intelligence

1. 모델 개요

1. π 범용 로봇 제어를 위한 VLA + Diffusion Flow Model
2. 백본: Paligemma VLM (~3B) + 액션 전문가(300M)
3. 학습 데이터: π Cross-Embodiment Dataset(다양한 로봇·환경)

2. VLM 구성

1. SigLIP(이미지 인코더) + Gemma(언어 명령)
2. 비전·언어 입력 처리, 액션 토큰 미포함 → 시각 이해 명확화

3. Action Expert (Flow Matching)



1. 비전·언어·로봇 상태 토큰 기반
2. 연속형 액션 시퀀스(H=50) 생성 → 부드러운 모션
3. 디퓨전 기반 점진적 노이즈 제거로 정밀 제어

4. 기존 VLA와 차별점

1. 연속형 액션 토큰나이제이션 → 고주파 제어(50Hz) 가능
2. 고난이도 작업에서 높은 효율성과 적응성



5. π -FAST 확장판

1. DCT기반 시퀀스 압축(저주파/고주파 분리)
2. 오토리그래시브 방식, 효율·속도 향상
3. 불필요한 고주파 성분 제거, 핵심 동작 정보 유지



π Physical Intelligence

- 소형 버전도 쉬운 과업부터 어려운 과업까지 성능 우위를 확보
- DCT :연속된 행동 토큰을 시간 영역에서 주파수 영역으로 변환
 - 저주파 성분(느리고 부드러운 변화)
 - 고주파 성분(빠르고 급격한 변화)
- 실제 환경 : 저주파 성분이 주로 의미 있는 정보
 - 고주파 성분은 무시하거나 추가 압축 가능
- $\pi 0$ -FAST
 - $\pi 0$ 의 확장 버전
 - 자기회귀 방식과 FAST 방식
 - 행동 시퀀스를 주파수 영역에서 토크나이징하여 중복을 줄임
 - > 효율성과 정밀도 향상



OpenVLA 대비 Pi0의 성능 우위 요인

🔑 OpenVLA 대비 Pi0의 성능 우위 요인

1. 사전학습 규모 차이 (VLM)

- OpenVLA: Open X-Embodiment(약 100만 에피소드) 중심.
- Pi0: 더 방대한 영상+텍스트 데이터로 VLM을 사전학습.
→ 시각-언어 표현력이 강화되어 더 다양한 환경에서 일반화 가능.

2. VLA 사전학습 데이터 품질

- OpenVLA: 범용 데이터셋 기반.
- Pi0: 10,000시간 규모의 정교한 로봇 시연 데이터 추가.
→ 단순히 양뿐만 아니라 고품질 trajectory 학습을 통해 정확성·안정성 향상.

3. 액션 표현 방식

- OpenVLA: Discrete action tokens (7차원 심볼릭 토큰) 기반 autoregressive 예측.
- Pi0: Flow Matching 기반 연속 action trajectory 생성.
 - Action-level 예측보다 연속적·세밀한 제어 가능.
 - 노이즈 제거 + smooth trajectory 보장 → 저수준 동작에서 안정적 성능 확보.
→ Low-level 제어 품질이 크게 향상.

4. 경량화 vs 성능

- 모델 크기는 OpenVLA(수십억 파라미터)보다 작음.
- 그러나 데이터 품질 + 학습 기법(Flow Matching) → 효율성 대비 성능 역전.
- 즉, "작지만 더 똑똑한 정책"이 됨.

📊 결론

- 사용자가 정리하신 대로
 1. 더 많은 VLM 사전학습 데이터,
 2. 정제된 10,000시간 로봇 데이터,
 3. Flow Matching 기반 저수준 제어이 세 가지가 OpenVLA보다 Pi0이 우수한 핵심 이유입니다.

Pi0 특징 요약

1. Physical Intelligence 설립 배경

- 로봇 애플리케이션마다 새로운 회사·연구실 수준의 노력이 필요 → 범용 로봇틱 파운데이션 모델 필요성 대두.
- LLM과 VLM처럼 범용적 지식 모델을 로봇에 적용 → “SF에서 보던 범용 로봇”의 기초 마련.
- 단기보다는 장기적 비전. 하지만 최근 수년간 필요한 기술적 요소들이 준비되었음.

2. 로봇틱 학습의 핵심 도전 과제

1. 데이터 부족

- 인터넷에는 이미지·텍스트 데이터는 풍부하지만, 로봇 데이터는 없음.
- 로봇 학습을 위해서는 직접 데이터 수집 필요 → 비용·노력 커짐.

2. 일반화와 상식 부족

- 로봇은 실제 환경에서 예상치 못한 상황 처리 필요.
- VLM을 통해 언어·시각 기반 상식을 주입 가능.

3. 성능·신뢰성

- 강화학습(RL) 발전이 정밀성·성능 향상에 기여.

3. Reinforcement Learning(강화학습)과 파운데이션 모델

- $\pi 0$ 자체에는 RL이 핵심 요소는 아님 → “초기 단계 모델”으로 위치.
- LLM이 먼저 사전학습·SFT·RLHF 단계를 밟은 것처럼, 로봇도 나중에 RL이 통합될 가능성 큼.
- RL은 특히 테스트 시점 추론(test-time reasoning), 세밀한 행동 최적화에 유용할 것.

4. $\pi 0$ 모델 아키텍처

- 기본 구조: VLM(Gemma 기반) + Action Expert.
- 문제: VLM은 이미지·텍스트 이해/생성은 잘하지만, 정밀한 연속 동작 표현은 어렵다.
- 해결: Diffusion 기반 Action Expert를 붙여, 연속 trajectory(action chunks)를 생성.
- 결과: 빨래 개기 등 복잡한 작업에서 안정적 성능. ---

5. 데이터 Recipe (Pre-training & Post-training)

• Pre-training (약 10,000시간)

- 인간 텔레오퍼레이션을 통해 수집한 다양한 과제 데이터.
- 실패·실수 데이터를 포함 → 로봇이 오류에서 복구하는 능력 학습.
- OXE(Open X-Embodiment) 데이터도 포함.

• Post-training (2~20시간, 소규모)

- 고품질·일관된 데이터, 특정 전문가가 시연한 전략 포함.
- 과제를 가장 잘 수행하는 방식을 학습.

- 교훈: 좋은 데이터만 있으면 오히려 일반화에 약점. 다양한 품질 데이터가 필요.

6. 데모 사례 – 빨래 개기

- 과제별 코드 변경 없음 → 같은 모델이 박스 조립, 테이블 청소에도 적용.
- 전략은 포스트 트레이닝 데이터로 학습.
- 예측 불가 상황은 프리 트레이닝 데이터에서 복구 능력을 습득.
- 실제 실험 중, 연구원이 셔츠를 방해 요소로 던지자 로봇이 스스로 치워 버리는 emergent behavior 관찰. ---

<https://www.youtube.com/watch?v=5mY7lrGXAkM>

Pi0 특징 요약

7. FAST (토크나이제이션 혁신)

- 기존 VLA는 액션을 단순 숫자 토큰으로 표현 → 비효율적.
- **FAST**: 주파수 도메인 압축(JPEG 유사) → 액션 토큰 균등화.
- 효과:
 - 학습 속도 **4배** 향상.
 - 동일 성능을 더 적은 토큰으로 구현.
 - 언어 지시 일반화 성능 개선.
- Hugging Face 공개, 누구나 적용 가능.

8. Open Sourcing (오픈소스 공개)

- 제공 내용:
 - 기본 체크포인트,
 - **FAST** 버전 체크포인트 + 토크나이저,
 - 파인튜닝 코드,
 - 예시 모델 (DROID, Aloha).
- 주요 목적: 연구자·커뮤니티가 직접 데이터 수집 → 자신의 로봇에 파인 튜닝.
- 기대 효과: 창의적 실험 유도 → 새로운 레시피·데이터 수집 방식 발견.

9. 지원 로봇 유형

- 팔 기반 로봇(단일/이중 팔), 휴머노이드, 모바일 플랫폼 지원.
- 32차원 이하 액션 공간이면 대부분 적용 가능.
- 실제 사례: 다섯 손가락 로봇 손, Franka 팔, 저가형 로봇 팔 등.
- Aloha 실험 장비: 약 \$20K, 팔 하나당 \$6K.
- 하드웨어 비용 지속 감소 → **향후 대중화** 가능성 큼.

9. 지원 로봇 유형

- 팔 기반 로봇(단일/이중 팔), 휴머노이드, 모바일 플랫폼 지원.
- 32차원 이하 액션 공간이면 대부분 적용 가능.
- 실제 사례: 다섯 손가락 로봇 손, Franka 팔, 저가형 로봇 팔 등.
- Aloha 실험 장비: 약 \$20K, 팔 하나당 \$6K.
- 하드웨어 비용 지속 감소 → **향후 대중화** 가능성 큼.

10. 향후 연구 방향

1. 복잡한 지시사항 이해
 - 단순 과제 지시("셔츠 접어") → 복합 지시("파티 준비, 접시는 두고 쓰레기만 치워라") 가능하게.
 - LLM처럼 상세 태스크 설명 기반 실행 목표.
2. 기술 재 활용·응용
 - 새로운 과제를 기존 기술 조합으로 해결하는 능력.
3. 일반화 성능 확장
 - 과제(Task), 환경(Environment), 객체(Object), 플랫폼(Platform), 지시사항(Instruction) 전반에 걸친 일반화.
 - 목표: "아하 모멘트(aha moment)"를 더 자주 제공.
 - 예: 모델을 다른 대학의 로봇에 올려 실행 → 바로 동작하는 경험.

✅ 결론:

π_0 는 아직 초기 단계지만,

- **Diffusion** 기반 **Action Expert**,
- **Pre-training + Post-training** 레시피,
- **FAST** 토크나이제이션,
- 오픈소스 공개

Helix by Figure AI

- 모델 성격

Closed-source 범용 VLA 모델
휴머노이드 로봇 제어용
약 500시간 멀티로봇 데이터로 지도학습

- 이중 시스템 구조

- System 2 (S2):


7B 파라미터 VLM 백본, 고수준 계획·이해,
저속(Thinking Slow)

- System 1 (S1):

80M 파라미터 비주얼-모터 변환기, 실시간 저수준 제어,
200Hz(Thinking Fast)
S2에서 생성한 잠재 벡터를 S1에 전달해 행동 조건화



- 특징

- 단일 신경망 가중치로 다중 작업 학습
(작업별 파인튜닝 불필요)
 - 상체 전체(머리, 손목, 손가락, 몸통) 고정밀 제어 가능
 - 실세계 OOD(Out-of-Distribution) 상황에서도 높은 성능
 - 완전 온보드 실행, 저전력, BMW 등 공장에 상용 배포




엔비디아 GROOT N1

- 모델 유형: 개방형(Open) 범용 휴머노이드 추론·제어 모델
- 파라미터 규모: 2B (eagle2_hg_model 백본)
- 학습 데이터: Omniverse·Cosmos 시뮬레이션 데이터 + 실제 휴머노이드 로봇 데이터
- 적응성: 사전 학습된 정책을 다양한 로봇 시스템에 이식 가능 (Cross-Embodied)
- 토큰화 입력: 관측(Observation), 언어 지시(Language Instruction), 로봇 상태(Robot State)
- 이중 시스템 구조:
 - System 2: VLM 기반 고수준 계획(물리 세계 이해·추론)
 - System 1: Diffusion Transformer 기반 저수준 제어(120Hz 모터 동작)



Gemini Robotics


- 개발사: Google DeepMind
- 기반 모델: Gemini 2.0 멀티모달
- 주요 특징:
 - 20Hz 고속 모터 제어
 - 정밀한 조작 및 복잡한 일상 작업 수행 가능
- 모델 구성:
 - Gemini Robotics-ER
 - 순수 Gemini 2.0 (로봇 액션 데이터 미세 조정 없음)
 - 시각-공간 관계 및 웹 사전학습 지식 기반
 - Gemini Robotics
 - 액션 데이터로 파인튜닝하여 직접 로봇 제어
 - 인지·추론·행동 생성을 단일 모델에서 처리
- 아키텍처:
 - 고수준 계획·인지: 클라우드 상 Gemini Robotics-ER 경량 버전
 - 저수준 실시간 제어: 로봇 온보드 액션 디코더
- 장점:
 - 네트워크 지연 보완 + 새로운 상황·환경에 대한 높은 일반화



$\pi_{0.5}$: a VLA with Open-World Generalization

개요

- $\pi_{0.5}$: VLA기반 로봇 지능 모델,
새로운 가정 환경에서도 일반화된 행동 수행
- 기존 π_0 모델 확장
이동 조작, 언어 명령 수행,
다양한 데이터 소스로부터의 공동 학습



$\pi_{0.5}$: a VLA with Open-World Generalization

1. 이중 제어 체계 (High- & Low-Level Control)

- 고수준 제어: 자연어 명령 이해 및 추론
(예: "접시를 싱크대에 넣어")
- 저수준 제어: 실제 관절 제어 동작 생성
(50단계 연속 명령)
- 동일한 모델이 두 기능을 "Chain-of-Thought" 방식으로 수행

2. Co-Training 기반 학습 전략

- 웹 데이터(캡셔닝, QA),
- 고정형 로봇의 다환경 시연 데이터(ME),
- 크로스 엠보디먼트 데이터(CE)
- 다양한 데이터 조합을 통해 범용성 강화


3. 다양한 환경에서의 일반화 (Generalization)

- 학습에 포함되지 않은 완전히 새로운 가정에서 로봇 투입
- 접시 정리, 침대 정돈, 바닥 청소 등 복잡한 장기 과업 수행
- 약 100개의 환경만으로 테스트 환경 학습 모델에 근접한 성능 달성



SmolVLA

- 약 4.5억 파라미터의 경량 Vision-Language-Action 모델로, 소비자 GPU나 CPU에서도 실행 가능한 소형 구조
- SmolVLM-2(SigLIP + SmoLLM2) 백본과 Flow-Matching Transformer 액션 모듈을 사용해 연속적인 로봇 동작을 직접 생성
- 레이어 스킵, 시각 토큰 축소, 교차/자기 주의 최적화, 비동기 추론을 통해 속도와 처리량을 크게 개선했습니다.



06

VLA의 숙제와 응용

VLA의 숙제 (Research & Development Challenges)

현재 VLA의 핵심 숙제는 작고 빠르면서도 범용적이고 정확한 제어를 구현하는 것이며, 이를 위해 데이터·모델·제어 알고리즘 세 축이 함께 발전해야 합니다. 실용화 단계에서는 물류·가정·의료·서비스 분야부터 상용화 가능성이 가장 높습니다.

과제	설명
1. 경량화	온디바이스·엣지 환경에서도 실시간 동작이 가능하도록 모델 파라미터 수와 연산량 을 줄여야 함. 양자화(Quantization), LoRA·QLoRA, 지식 증류(Knowledge Distillation) 등이 핵심 기술.
2. 일반화	웹 데이터, 시뮬레이션·현실 혼합 데이터, Cross-Embodiment 학습 등을 활용해 다양한 환경과 태스크에 빠르게 적응 할 수 있는 능력을 확보해야 함. 현재는 특정 환경/로봇 종속성이 높음.
3. Low-Level 정확성	초당 50~200Hz 수준의 고주파수 제어 에서 오차 누적 없이 정밀한 관절·그리퍼 제어 필요. Diffusion Policy, Flow Matching, FAST 등의 시계열 압축·보정 기술 중요.
4. 안전성과 신뢰성	실제 산업·가정 환경에 투입되려면 안전 제어 , 예외 상황 회피, 인간-로봇 협업에서의 신뢰성 확보 가 필수. 특히 비정형 환경에서의 예측 불가능한 행동 방지가 필요.
5. 데이터 품질 확보	VLA 성능의 절반 이상은 데이터 품질과 다양성 에서 결정됨. 웹·시물·실세계 데이터의 밸런스와 정제 프로세스가 중요.

VLA의 응용

번호	응용 분야	설명
1	창고·물류 자동화	AMR, 로봇암, 피킹 시스템 통합 → 다품종 소량 주문 처리
2	가정용 정리·청소 로봇	주방·침실·거실 등 비정형 환경에서 명령 기반 정리·청소
3	산업용 조립 로봇	다양한 부품을 상황 인식 후 조립, 볼트 체결, 부품 적재
4	의료·간병 로봇	고령자 보조, 약 전달, 식사 지원, 재활 보조
5	농업 로봇	과일·채소 수확, 잡초 제거, 병해충 탐지
6	건설 현장 로봇	벽돌 쌓기, 페인트칠, 자재 이송, 안전 점검
7	우주·심해 탐사 로봇	원격 환경에서 탐사·샘플 채취, 장애물 회피
8	재난 구조 로봇	붕괴 현장 수색, 위험 지역 진입 및 생존자 구조
9	서비스 로봇	카페·호텔·레스토랑에서 주문·서빙·청소
10	교육·연구 로봇	로봇공학·AI 교육용 플랫폼, 연구 실험 환경